

```
In [1]: import pandas as pd
        from IPython.display import display

        df = pd.read_csv('data.csv')
        num_cols = df.select_dtypes(include='number').columns
        cat_cols = df.select_dtypes(exclude='number').columns
```

```
In [2]: print('Rozmiar zbioru:', df.shape)
        print("WNIOSKI: 418 wierszy to niewiele")
```

Rozmiar zbioru: (418, 20)
WNIOSKI: 418 wierszy to niewiele

```
In [3]: print('\nTypy danych:')
        display(df.dtypes.to_frame('dtype'))
```

Typy danych:

	dtype
ID	int64
N_Days	int64
Status	str
Drug	str
Age	int64
Sex	str
Ascites	str
Hepatomegaly	str
Spiders	str
Edema	str
Bilirubin	float64
Cholesterol	float64
Albumin	float64
Copper	float64
Alk_Phos	float64
SGOT	float64
Tryglicerides	float64
Platelets	float64
Prothrombin	float64
Stage	float64

```
In [4]: missing_info = df.isna().sum().to_frame('missing_values')
        missing_info['percentage'] = (df.isna().mean() * 100).round(2).astype(str) + '%'
```

```
print('\nBraki danych w kolumnach:')
display(missing_info)

print("WNIOSKI: 9 kolumn ma braki danych powyżej 25%")
```

Braki danych w kolumnach:

	missing_values	percentage
ID	0	0.0%
N_Days	0	0.0%
Status	0	0.0%
Drug	106	25.36%
Age	0	0.0%
Sex	0	0.0%
Ascites	106	25.36%
Hepatomegaly	106	25.36%
Spiders	106	25.36%
Edema	0	0.0%
Bilirubin	0	0.0%
Cholesterol	134	32.06%
Albumin	0	0.0%
Copper	108	25.84%
Alk_Phos	106	25.36%
SGOT	106	25.36%
Tryglicerides	136	32.54%
Platelets	11	2.63%
Prothrombin	2	0.48%
Stage	6	1.44%

WNIOSKI: 9 kolumn ma braki danych powyżej 25%

```
In [5]: print('\nPodstawowe statystyki dla cech liczbowych:')
display(df[num_cols].describe().T)

print("WNIOSKI:")
print("najmłodszy pacjent miał 26 lat, natomiast większość pacjentów (25%-75%) j
print("czas obserwacji (n-days) jest bardzo rozpięty, sugeruje to duże zróżnicow
```

Podstawowe statystyki dla cech liczbowych:

	count	mean	std	min	25%	50%	75%
ID	418.0	209.500000	120.810458	1.00	105.2500	209.50	313.75
N_Days	418.0	1917.782297	1104.672992	41.00	1092.7500	1730.00	2613.50
Age	418.0	18533.351675	3815.845055	9598.00	15644.5000	18628.00	21272.50
Bilirubin	418.0	3.220813	4.407506	0.30	0.8000	1.40	3.40
Cholesterol	284.0	369.510563	231.944545	120.00	249.5000	309.50	400.00
Albumin	418.0	3.497440	0.424972	1.96	3.2425	3.53	3.77
Copper	310.0	97.648387	85.613920	4.00	41.2500	73.00	123.00
Alk_Phos	312.0	1982.655769	2140.388824	289.00	871.5000	1259.00	1980.00
SGOT	312.0	122.556346	56.699525	26.35	80.6000	114.70	151.90
Tryglicerides	282.0	124.702128	65.148639	33.00	84.2500	108.00	151.00
Platelets	407.0	257.024570	98.325585	62.00	188.5000	251.00	318.00
Prothrombin	416.0	10.731731	1.022000	9.00	10.0000	10.60	11.10
Stage	412.0	3.024272	0.882042	1.00	2.0000	3.00	4.00

WNIOSKI:

najmłodszy pacjent miał 26 lat, natomiast większość pacjentów (25%-75%) jest w wieku pomiędzy 42-58 lat

czas obserwacji (n-days) jest bardzo rozpięty, sugeruje to duże zróżnicowanie postępowania choroby/bardzo różne fazy rozpoznania choroby i udania się do szpitala

```
In [6]: print(df['Stage'].value_counts().sort_index())
print("Widzimy że zdecydowana większość pacjentów w zbiorze jest w ciężkim stanie")
```

Stage

1.0 21

2.0 92

3.0 155

4.0 144

Name: count, dtype: int64

Widzimy że zdecydowana większość pacjentów w zbiorze jest w ciężkim stanie (3 i 4 stadium choroby)

```
In [7]: for col in cat_cols:
        print(f"\nCecha: {col}")
        counts = df[col].value_counts(dropna=False)
        percents = df[col].value_counts(normalize=True, dropna=False) * 100
        summary = pd.concat([counts, percents.round(2)], axis=1, keys=['Liczba', 'Pr
        display(summary)

        print("WNIOSKI")
        print("zdecydowana większość wierszy to kobiety")
        print("liczność ludzi przyjmujących placebo i d-pecicylamine jest prawie równe")
        print("bardzo mało osób miało przeszczep, prawie 40% przypadków ze zbioru zakońc
```

Cecha: Status

	Liczba	Procent %
Status		
C	232	55.50
D	161	38.52
CL	25	5.98

Cecha: Drug

	Liczba	Procent %
Drug		
D-penicillamine	158	37.80
Placebo	154	36.84
NaN	106	25.36

Cecha: Sex

	Liczba	Procent %
Sex		
F	374	89.47
M	44	10.53

Cecha: Ascites

	Liczba	Procent %
Ascites		
N	288	68.90
NaN	106	25.36
Y	24	5.74

Cecha: Hepatomegaly

	Liczba	Procent %
Hepatomegaly		
Y	160	38.28
N	152	36.36
NaN	106	25.36

Cecha: Spiders

	Liczba	Procent %
Spiders		
N	222	53.11
NaN	106	25.36
Y	90	21.53

Cecha: Edema

	Liczba	Procent %
Edema		
N	354	84.69
S	44	10.53
Y	20	4.78

WNIOSKI

zdecydowana większość wierszy to kobiety

liczność ludzi przyjmujących placebo i d-pecicylamine jest prawie równe

bardzo mało osób miało przeszczep, prawie 40% przypadków ze zbioru zakończyło się śmiercią

```
In [8]: print('\nRozkład etykiety Stage:')
display(df['Stage'].value_counts(dropna=False).sort_index().to_frame('count'))
print("widzimy że zdecydowana większość przypadków w zbiorze to przypadki o dwóch
```

Rozkład etykiety Stage:

	count
Stage	
1.0	21
2.0	92
3.0	155
4.0	144
NaN	6


widzimy że zdecydowana większość przypadków w zbiorze to przypadki o dwóch najwyższych stadiach choroby, co może tłumaczyć wysoką śmiertelność, która była wnioskiem w poprzedniej komórce

```
In [9]: import seaborn as sns
import matplotlib.pyplot as plt

plt.figure(figsize=(12, 8))
corr_matrix = df[num_cols].corr()
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt=".2f", square=True)
plt.title('Macierz korelacji dla cech liczbowych')
plt.show()

print("WNIOSKI:")
print("1. Występuje zauważalna dodatnia korelacja (0.43) między poziomem albumin
```

```
print("2. Czas (N_Days) jest ujemnie skorelowany z poziomem bilirubiny (-0.40),  
print("3. Zmienne takie jak Wiek (Age) oraz Płytki krwi (Platelets) są bardzo sł
```



WNIOSKI:

1. Występuje zauważalna dodatnia korelacja (0.43) między poziomem albumin a liczbą dni (N_Days). Może to oznaczać, że pacjenci z wyższym poziomem tego białka charakteryzują się dłuższym okresem przeżycia (lub dłuższą obserwacją w badaniu).
2. Czas (N_Days) jest ujemnie skorelowany z poziomem bilirubiny (-0.40), stadiem choroby (Stage: -0.37) oraz poziomem miedzi (-0.36). Im bardziej zaawansowane stadium i wyższe stężenie tych toksycznych substancji, tym krótszy czas obserwacji pacjenta, co najprawdopodobniej wiąże się z szybszym zgonem.
3. Zmienne takie jak Wiek (Age) oraz Płytki krwi (Platelets) są bardzo słabo skorelowane z większością pozostałych cech. Oznacza to, że wiek pacjenta nie determinuje wprost wartości tych wyników biochemicznych w tym konkretnym zbiorze danych.

```
In [10]: crosstab_drug = pd.crosstab(df['Drug'], df['Status'], normalize='index') * 100  
display(crosstab_drug.round(2).astype(str) + '%')  
  
drug_stats = df.groupby('Drug')[['Bilirubin', 'Prothrombin', 'Copper']].mean()  
display(drug_stats.round(2))  
  
print("WNIOSKI:")  
print("1. Branie leku vs placebo nie wpływa znacząco na przeżywalność pacjenta")  
print("2. Średni poziom bilirubiny jest niższy u pacjentów leczonych D-penicylam
```

Status	C	CL	D
Drug			
D-penicillamine	52.53%	6.33%	41.14%
Placebo	55.19%	5.84%	38.96%

	Bilirubin	Prothrombin	Copper
Drug			
D-penicillamine	2.87	10.65	97.64
Placebo	3.65	10.80	97.65


WNIOSKI:

1. Branie leku vs placebo nie wpływa znacząco na przeżywalność pacjenta
2. Średni poziom bilirubiny jest niższy u pacjentów leczonych D-penicylaminą (2.87) w porównaniu do grupy placebo (3.65), co może sugerować, że lek ma łagodzący wpływ na ten konkretny parametr wątrobowy.

```
In [11]: df['Age_years'] = df['Age'] / 365.25

plt.figure(figsize=(10, 6))
sns.histplot(data=df, x='Age_years', hue='Status', multiple='stack', bins=20, pa
plt.title('Dystrybucja wieku pacjentów (w latach) w podziale na Status')
plt.xlabel('Wiek (lata)')
plt.ylabel('Liczba pacjentów')
plt.show()

print("WNIOSKI:")
print("- Rozkład zgonów (Status D) jest zauważalnie przesunięty w prawo, co ozna
print("- W grupie pacjentów nie seniorów (przed 60), znacznie częściej obserwuje
```



WNIOSKI:

- Rozkład zgonów (Status D) jest zauważalnie przesunięty w prawo, co oznacza, że starsi pacjenci (szczególnie powyżej 45 roku życia) stanowią największą grupę ryzyka.
- W grupie pacjentów nie seniorów (przed 60), znacznie częściej obserwujemy status C (pacjenci ocalejący/żyjący na koniec badań).